编译原理

实

验

报

告

实验名称：实验一：词法分析

姓名：方澳阳

学号：180110115

学院：计算机科学与技术

专业：计算机类

一、 实验目的与方法

（1）通过本实验加深对词法分析程序的功能及实现方法的理解

（2）设计并编程实现一个词法分析程序，对 C 语言源程序段进行词法分析，加深对高级语言的认识

（3）对 C 语言的文法描述有更深的认识，体会有穷自动机，编码表和符号表在编译的整个过程中的应用

实现语言: C++

环境: Clion2020.2

二、 实验总体流程与函数功能描述

流程：

1. 将代码串读取进来
2. 根据编码表初始化 c 实验的种别码
3. 对读进来的代码串进行扫描，循环判断读进来的字符串，将其转为 token。
4. 遍历所有 token 串，将标识符存到符号表中，并且初始化其他字段。

read_program(): 从 txt 文件中读取代码,存到 program
initMap(): 初始化 C 语言的种别码
getNext(); 使 pos 指针加 1,使 ch 为下一个字符
scanner(); 扫描器,对 ch 进行判断,存入对应的 token 串中

三、 实验内容

使用正则文法:

正则文法$G=(V，T，P，S)$中，对$\forall\alpha\rightarrow\beta\in P$，$\alpha\rightarrow\beta$均具有形式$A\rightarrow w$或$A\rightarrow wB(A\rightarrow w$或$A\rightarrow Bw)$，其中$A$，$B\in V$，$w\in T^{+}$。

标识符\关键字的文法描述：

$$<id>\rightarrow<letter>|<id><digit>|<id><letter>$$

$$<letter>\rightarrow A|B|...|Z|a|b|...|z$$

$$<digit>\rightarrow 0|1|2|...|9$$

常数的文法描述：

$< digit > \rightarrow 0|1|2|...|9|.< digits >$

$< digits > \rightarrow 0|1|2|...|9$

运算符的文法描述：

$< op > \rightarrow +|-|*|/|\&|\hat{}|||...|<|>|=$

有穷自动机：

1. 检测标识符\关键字

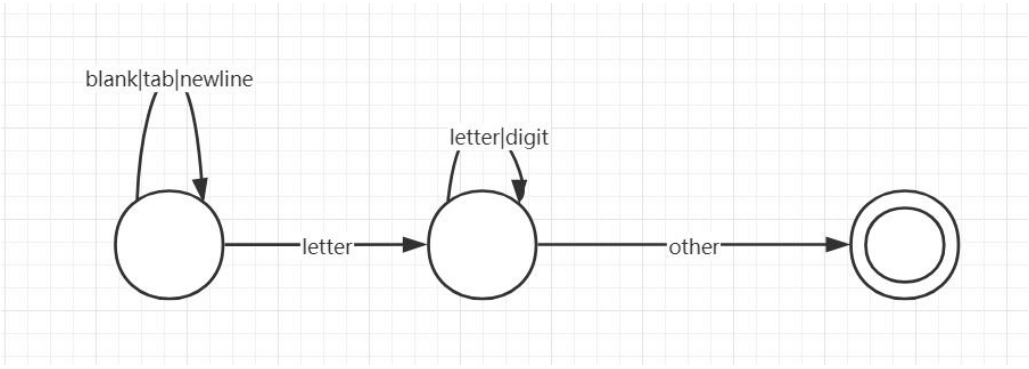

2. 检测常数

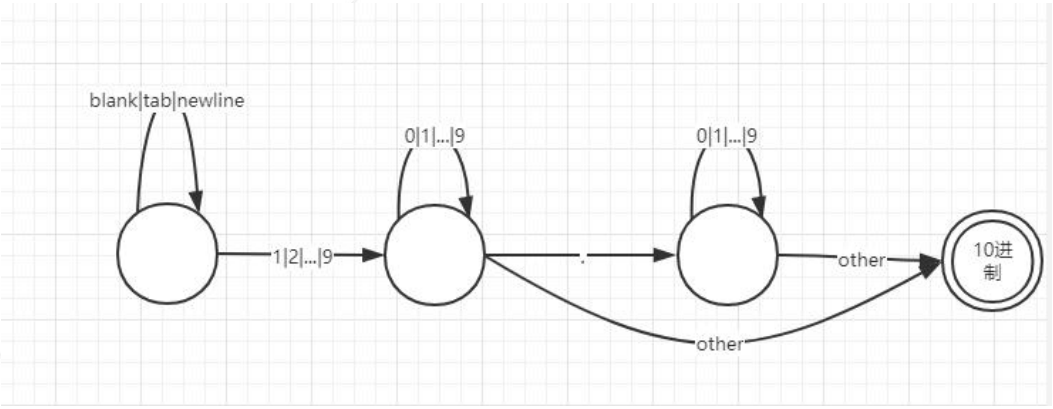

3. 检测分界符以及特殊运算符(因为他们的状态转移相同，所以合并成一个状态)

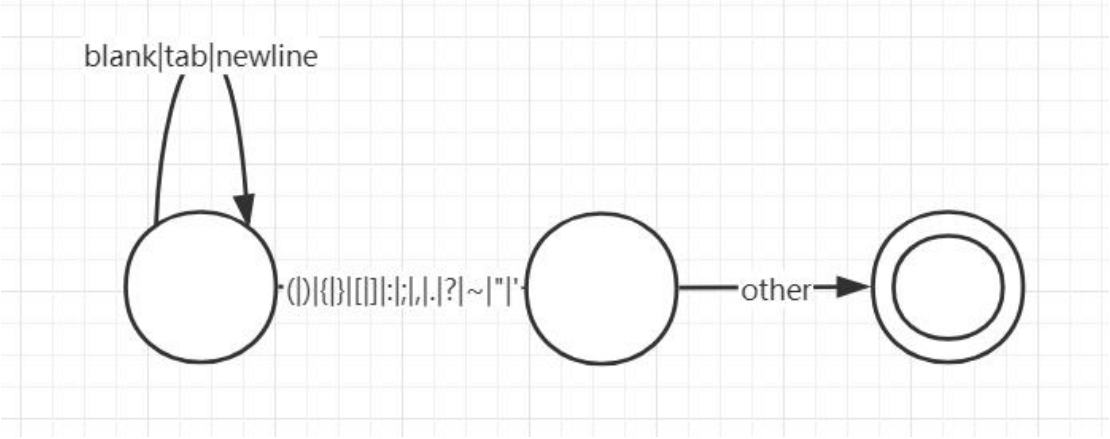

4. 检测运算符

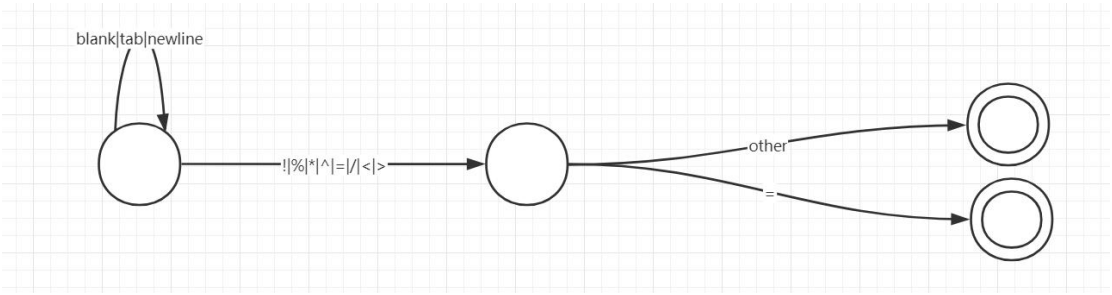
blank|tab|newline
!|%|*|^|=|/|<|>
other
=

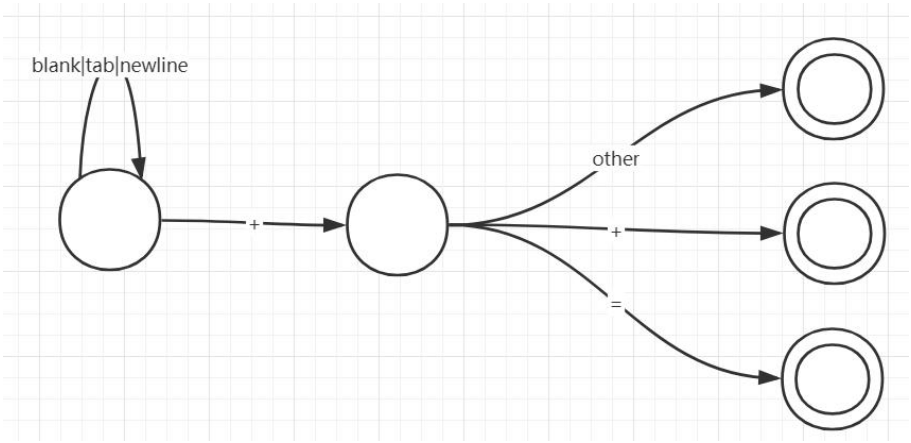
blank|tab|newline
+
other
+
=

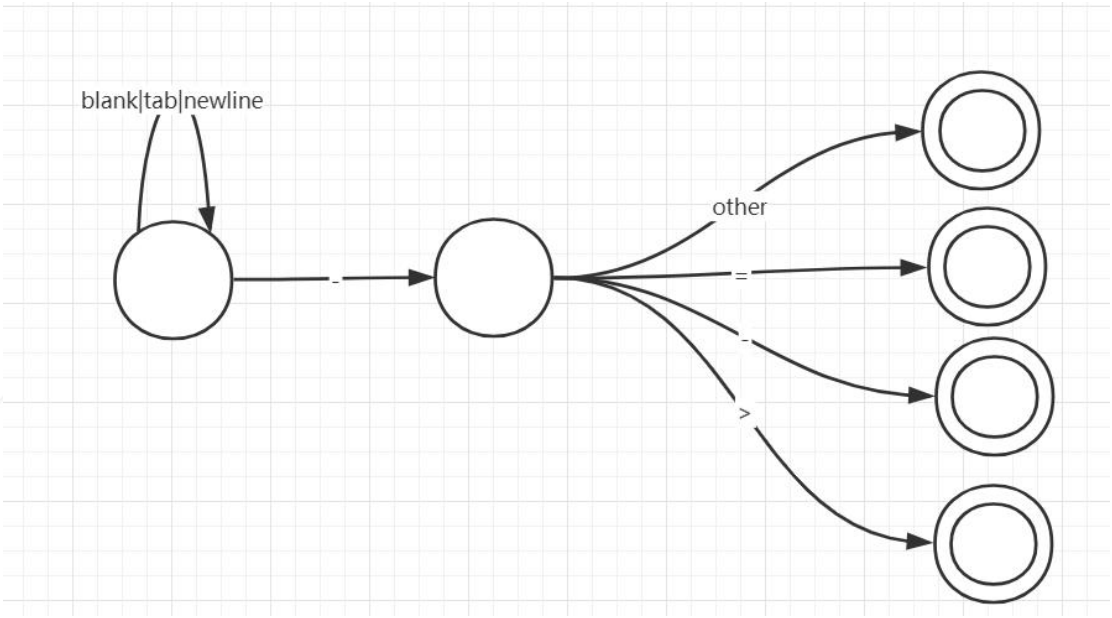
blank|tab|newline
-
other
=
-
>

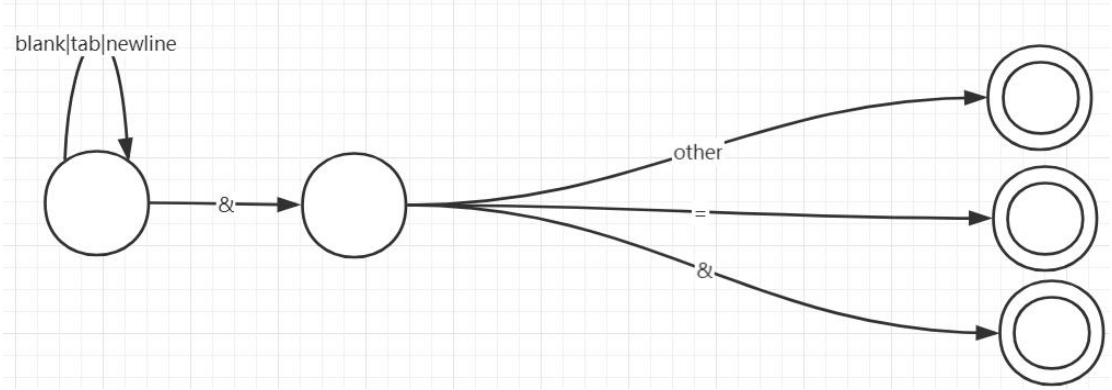
blank|tab|newline
&
other
=
&

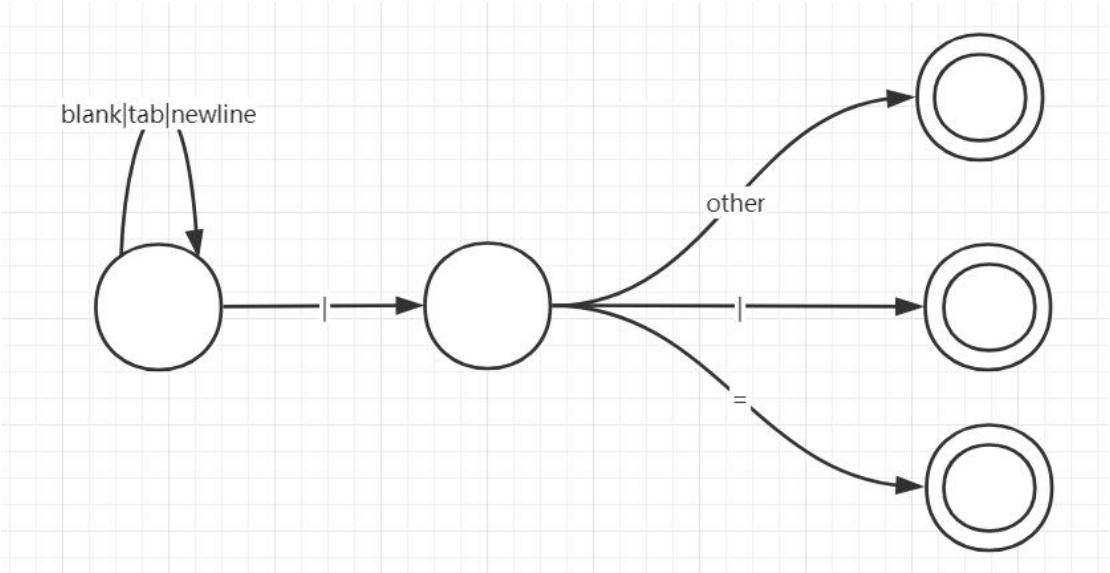

编码表：

auto	1	switch	26	/ =	51
break	2	typedef	27	:	52
case	3	union	28	;	53
char	4	unsigned	29	?	54
const	5	void	30	[	55
continue	6	volatile	31	]	56
default	7	while	32	^	57
do	8	-	33	^	58

double	9	=	34	{	59		
else	10	-=	35	|	60		
enum	11	->	36	||	61		
extern	12	!	37	|=	62		
float	13	!=	38	}	63		
for	14	%	39	~	64		
goto	15	%=	40	+	65		
if	16	&	41	++	66		
int	17	&&	42	+=	67		
long	18	&=	43	<	68		
register	19	(	44	<<	69		
return	20	)	45	<<=	70		
short	21	*	46	<=	71		
signed	22	*	47	=	72		
sizeof	23	,	48	==	73		
static	24	.	49	>	74		
struct	25	/	50	>=	75		
>>	76	\	78	#	80		
>>=	77	\=	79	/*注释*/	81		
常数	82	标识符	83				

Token 串和符号表的逻辑结构及存贮结构

Token 串的存储使用一个动态数组存储，定义为

vector<pair<int,string>>

数组中的每一个元素为一个 pair，pair.first 代表种类，pair.second 表示具体的串。当 pair.first 为标识符时，可以通过 pair.second 去符号表中索引到对应的信息。

符号表使用 Map 作为存储结构。通过设置对应的 string 串作为 key，可以在 Map 中得到其对应的 value。符号表定义为

map<string,SYSTABLE> sysMap

其中，SYSTABLE 为一个类，里面存储了对应标识符的 type 和 address。

算法描述

1. 由于在实现过程中需要大量地用到“将指针移动到下一个字符”的操作,因此将该操作封装成一个函数，并且包括错误检测。

```
bool getNext(char &ch, string::size_type &pos, const string &program) {
    pos++;
    if (pos >= program.size()) {
        return false;
    } else {
        ch = program[pos];
        return true;
    }
}
```

2. 判断用到了 sanner 函数，其逻辑为:
   (1) 先判断从指针 pos 开始的字符串是否为标识符或者关键字，若是，则按照正则文法给出的状态机将 pos 往后移，直到遇到不符合标识符或关键字文法的字符。
   (2) 再判断是否为常数。
   (3) 再判断是否为标识符。
   (4) 函数返回一个 pair，表示一个 token。
3. 以上两步完成后, 则需要遍历所有的 token 串。
   (1) 如果 token 串表明该串是一个标识符，则将该串作为 key，新建一个 value 对象（即 SYSTABLE），填入到符号表中。
   (2) 如果不是则跳过
   (3) 重复以上步骤，直到遍历结束所有的 token

由于 C++中的 map 可以保证关键字的唯一性，所以该方法可行。

四、 实验结果与分析

输入的代码串,该代码实现的是冒泡排序:

```
#include <stdio.h>
void bubble_sort(int a[], int n);
int number[10000000];
void bubble_sort(int a[], int n)
{
    int i,j,temp;
    for (j=0;j<n-1;j++)
    {
        for (i=0;i<n-1-j;i++)
        {
            if(a[i]>a[i+1])
            {
                temp=a[i];
                a[i]=a[i+1];
                a[i+1]=temp;
            }
        }
    }
}

int main()
{
    int i,n;
    scanf("%d",&n);
    for(int j=0;j<n;j++)
        scanf("%d",&number[j]) ;
    bubble_sort(number,n);
    for (i=0;i<n-1;i++)
        printf("%d ",number[i]);
    printf("%d\n",number[i]);
    return 0;
}
```

输出的 token 串:

```
(80,#)
(83,include)
(68,<)
(83,stdio)
(82,.)
(83,h)
(74,>)
```

```
(30,void)
(83,bubble_sort)
(44,()
(17,int)
(83,a)
(55,[)
(0,])
(48,,)
(17,int)
(83,n)
(45,))
(53,;)
(17,int)
(83,number)
(55,[)
(82,10000000)
(0,])
(53,;)
(30,void)
(83,bubble_sort)
(44,()
(17,int)
(83,a)
(55,[)
(0,])
(48,,)
(17,int)
(83,n)
(45,))
(59,{)
(17,int)
(83,i)
(48,,)
(83,j)
(48,,)
(83,temp)
(53,;)
(14,for)
(44,()
(83,j)
(72,=)
(82,0)
(53,;)
(83,j)
```

(68,<)
(83,n)
(33,-)
(82,1)
(53,;)
(83,j)
(66,++)
(45,))
(59,{)
(14,for)
(44,()
(83,i)
(72,=)
(82,0)
(53,;)
(83,i)
(68,<)
(83,n)
(33,-)
(82,1)
(33,-)
(83,j)
(53,;)
(83,i)
(66,++)
(45,))
(59,{)
(16,if)
(44,()
(83,a)
(55,[)
(83,i)
(0,])
(74,>)
(83,a)
(55,[)
(83,i)
(65,+)
(82,1)
(0,])
(45,))
(59,{)
(83,temp)
(72,=)

(83,a)
(55,[)
(83,i)
(0,])
(53,;)
(83,a)
(55,[)
(83,i)
(0,])
(72,=)
(83,a)
(55,[)
(83,i)
(65,+)
(82,1)
(0,])
(53,;)
(83,a)
(55,[)
(83,i)
(65,+)
(82,1)
(0,])
(72,=)
(83,temp)
(53,;)
(63,})
(63,})
(63,})
(63,})
(17,int)
(83,main)
(44,()
(45,))
(59,{)
(17,int)
(83,i)
(48,,)
(83,n)
(53,;)
(83,scanf)
(44,()
(78,")
(39,%)

(83,d)
(78,")
(48,,)
(41,&)
(83,n)
(45,))
(53,;)
(14,for)
(44,()
(17,int)
(83,j)
(72,=)
(82,0)
(53,;)
(83,j)
(68,<)
(83,n)
(53,;)
(83,j)
(66,++)
(45,))
(83,scanf)
(44,()
(78,")
(39,%)
(83,d)
(78,")
(48,,)
(41,&)
(83,number)
(55,[)
(83,j)
(0,])
(45,))
(53,;)
(83,bubble_sort)
(44,()
(83,number)
(48,,)
(83,n)
(45,))
(53,;)
(14,for)
(44,()

```
(83,i)
(72,=)
(82,0)
(53,;)
(83,i)
(68,<)
(83,n)
(33,-)
(82,1)
(53,;)
(83,i)
(66,++)
(45,))
(83,printf)
(44,()
(78,")
(39,%)
(83,d)
(78,")
(48,,)
(83,number)
(55,[)
(83,i)
(0,])
(45,))
(53,;)
(83,printf)
(44,()
(78,")
(39,%)
(83,d)
(0,\n)
(78,")
(48,,)
(83,number)
(55,[)
(83,i)
(0,])
(45,))
(53,;)
(20,return)
(82,0)
(53,;)
(63,})
```

输出的符号表

```
(a, -1, ?)
(bubble_sort, -1, ?)
(d, -1, ?)
(h, -1, ?)
(i, -1, ?)
(include, -1, ?)
(j, -1, ?)
(main, -1, ?)
(n, -1, ?)
(number, -1, ?)
(printf, -1, ?)
(scanf, -1, ?)
(stdio, -1, ?)
(temp, -1, ?)
```

五、实现的拓展功能

可以识别八进制、十六进制常数。

有穷自动机如下所示，即在识别 10 进制的常数的基础上进行一些修改即可。

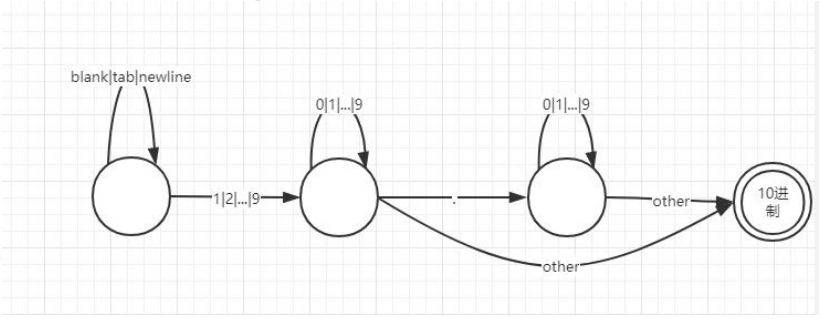

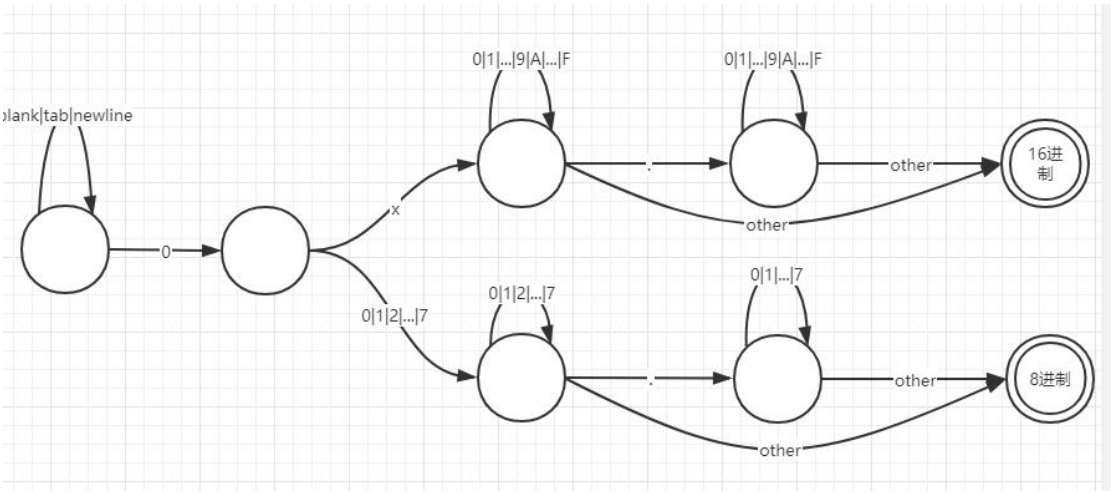

六、实验中遇到的困难与解决办法

在实验的过程中一开始不知道要做什么，因为从理论到实际还是有一定差距的。并且在实验指导书中给出的输出的例子有一些错误，指导思想不是很明确。再加上自己对于编译的整个过程不是很理解，导致不明白一些概念。

例如符号表中后面这些-1 和？的含义。

```
(s,-1,?)
(mul_x,-1,?)
(test,-1,?)
(a,-1,?)
(b,-1,?)
(printf,-1,?)
```

在与老师沟通交流之后，才明白这些空白需要在后面语法分析、语法制导等过程中再逐渐补充的。并且也知道了实现方式可以多种多样，例如我这次使用了 c++的一些 STL 库中的数据结构，这比自己用 c 造出一个数据结构更加方便。

但是这次实验做的也有很多不足，例如使用了大量的 switch case 语句，导致代码重复性高，没有尽可能地复用代码。整个词法分析的实现也相当的“原始”，只是对有可能出现的情况进行分类讨论，没有做到根据输入动态调整。